

ПРИМЕР ИТОГОВОЙ АНАЛИТИЧЕСКОЙ РАБОТЫ

Операционная аналитика интернет-магазина:
продажи, возвраты, SLA доставки и клиентские сегменты

Эталонный отчет для разбора на консультации

Предметная область: российская электронная коммерция
Период данных: январь 2024 - декабрь 2025
Инструменты: Python, pandas, scipy, scikit-learn, Yandex DataLens

Назначение документа

Отчет демонстрирует полный путь итоговой работы: от бизнес-вопроса и консолидации данных до статистических гипотез, ABC-XYZ, RFM, BI-дашборда и управленческих рекомендаций. Все числа воспроизводятся из приложенных CSV и notebook.

Содержание

Резюме для руководителя

1. 1. Бизнес-контекст и постановка задачи
2. 2. Данные и аналитическая модель
3. 3. Методология исследования
4. 4. ETL и контроль качества
5. 5. Исследовательский анализ
6. 6. Проверка гипотез
7. 7. ABC-XYZ-анализ
8. 8. RFM-анализ
9. 9. Аналитическое приложение в DataLens
10. 10. Рекомендации
11. 11. Ограничения
12. 12. Заключение

Приложения и источники

Резюме для руководителя

Проанализировано 35,915 заказов и 6,143 клиентов за 2024-2025 годы. Признанная выручка составила 328 104 971 руб., валовая прибыль - 88 110 930 руб., совокупная маржинальность - 26,9%. Доля возвратов составила 6,6%, а доля нарушений SLA среди заказов, включенных в контроль сроков, - 30,7%.

Показатель	Значение	Интерпретация	Управленческий фокус
Выручка	328 104 971 руб.	Масштаб выполненных продаж	Планирование роста и сезонных пиков
Валовая прибыль	88 110 930 руб.	Финансовый результат после прямых затрат	Контроль категории, скидок и возвратов
Маржинальность	26,9%	Отношение совокупной прибыли к выручке	Не усреднять строковый margin_pct
Возвраты	6,6%	Доля заказов со статусом returned	Особое внимание одежде и обуви
Нарушения SLA	30,7%	Просрочки относительно обещанного срока	Региональные и сезонные риски

Ключевые результаты

- Категория с наибольшей выручкой - Электроника: 170 954 687 руб..
- Максимальный риск SLA зафиксирован в регионе «Новосибирская область»: 51,0%.
- Возвраты в одежде и обуви составили 14,5% против 5,5% в остальных категориях; различие статистически значимо.
- Экспресс-доставка имеет долю нарушений SLA 22,8%, стандартная - 34,0%.
- Заказы со скидкой от 20% имеют среднюю маржинальность 22,8% против 35,7% у остальных доставленных заказов.

1. Бизнес-контекст и постановка задачи

Российская интернет-торговля продолжает расти и становится существенной частью розничного рынка. Для учебного кейса выбрана операционная аналитика условного интернет-магазина «СеверМаркет Онлайн». Компания продает товары шести категорий в двенадцати регионах и использует веб-сайт, мобильное приложение и маркетплейсы как каналы продаж.

Рост оборота сам по себе не гарантирует улучшения финансового результата: сезонные пики увеличивают нагрузку на доставку, скидки могут снижать маржу, а возвраты перераспределяют затраты между товарными категориями. Поэтому итоговая работа отвечает одновременно на вопросы продаж, прибыльности, клиентского поведения и операционного качества.

Цель исследования

Выявить факторы выручки, маржинальности, возвратов и нарушения SLA, сегментировать клиентов и товарный портфель, а затем подготовить интерактивное аналитическое приложение для управленческого контроля.

Задачи

- Консолидировать четыре источника данных.
- Очистить и трансформировать данные с фиксацией правил качества.
- Провести EDA и сформулировать численные выводы.

- Проверить статистические гипотезы.
- Выполнить ABC-XYZ и RFM-анализ.
- Сформировать витрину и спецификацию дашборда DataLens.
- Подготовить рекомендации, KPI контроля и ограничения.

Гипотезы

Код	Гипотеза	Метод	Критерий решения
H1	Тип доставки связан с нарушением SLA	Хи-квадрат	$p < 0,05$
H2	Одежда и обувь возвращается чаще других категорий	Хи-квадрат	$p < 0,05$ и доля выше
H3	Высокая скидка меняет размер заказа и снижает маржу	Манна-Уитни	$p < 0,05$

2. Данные и аналитическая модель

Учебный набор данных сформирован синтетически, но повторяет типичную структуру e-commerce. Он не содержит персональных данных. На входе используются четыре таблицы.

Файл	Гранулярность	Ключ	Строк	Назначение
orders.csv	Один заказ	order_id	36090	Факты заказа, доставка, статус, скидка
customers.csv	Один клиент	customer_id	7000	Регион, тип клиента, лояльность
products.csv	Один товар	product_id	120	Категория, цена, себестоимость
regions.csv	Один регион	region_id	12	Макрорегион и координаты

Гранулярность итоговой витрины

Одна строка соответствует одному заказу. Уникальный ключ - order_id. Все справочные признаки денормализованы в витрину, чтобы исключить неоднозначность JOIN в BI и упростить сверку показателей.

Схема объединения

orders.customer_id -> customers.customer_id; orders.product_id -> products.product_id; orders.region_id -> regions.region_id. Для всех справочников ожидается связь many-to-one. После каждого объединения проверяется количество строк, уникальность order_id и пропуски в присоединенных полях.

3. Методология исследования

Этап	Действие	Результат
Business understanding	Формулировка бизнес-вопросов и KPI	Паспорт исследования
Data understanding	Профилирование таблиц, типов и качества	Диагностическая таблица
Data preparation	Очистка, стандартизация, JOIN, расчеты	Аналитическая витрина
Modeling / analysis	EDA, тесты, ABC-XYZ, RFM, ML опционально	Выводы и сегменты
Evaluation	Сверка метрик и интерпретация ограничений	QA и рекомендации
Deployment	DataLens, отчет, доступ к дашборду	Аналитическое приложение

4. ETL и контроль качества

Проблема	Количество	Правило обработки	Контроль
Повторяющиеся order_id	90	Оставить первую запись	order_id уникален
Некорректные даты	35	Преобразовать с errors=coerce и исключить	Диапазон 2024-2025
quantity <= 0 или unit_price <= 0	50	Исключить по бизнес-правилу	Положительные значения
Пропуски region_id	95	Восстановить из home_region_id клиента	После ETL пропусков нет
Разный регистр и пробелы channel	120	strip + lower	Три допустимых значения

После очистки в витрине осталось 35,915 строк. Потери данных связаны только с заранее заложенными ошибками даты и нарушениями бизнес-правил. Пропуски региона восстановлены по профилю клиента, поэтому строки не удалялись.

Расчет показателей

Показатель	Формула	Комментарий
Gross order value	quantity * unit_price	Сумма до скидки
Net order value	gross - discount	Стоимость после скидки
Recognized revenue	net value только для delivered	Возвраты и отмены не признаются выручкой
Gross profit	revenue + delivery fee - cost - return cost	Возвраты создают отрицательный вклад
SLA violation	actual_days > promised_days	Pickup и cancelled не входят в знаменатель
Margin %	SUM(profit) / SUM(revenue)	Не использовать среднее строковых процентов

5. Исследовательский анализ данных

5.1. Динамика




Рисунок 1. Динамика выручки и валовой прибыли по месяцам

Показатели растут в ноябре и декабре, когда усиливаются сезонные кампании. При этом линия прибыли растет медленнее выручки: в пиковые периоды увеличиваются скидки, нагрузка на доставку и возвраты. Для управленческого контроля необходимо отслеживать одновременно выручку и маржу, а не только оборот.

5.2. Товарные категории




Рисунок 2. Выручка по категориям

Наибольший вклад дает категория «Электроника». Однако категория-лидер по обороту не обязательно является лидером по маржинальности: максимальная маржинальность наблюдается в категории «Спорт и отдых» - 35,1%.




Рисунок 3. Доля возвратов по категориям

Одежда и обувь формирует наиболее высокий уровень возвратов - 14,5%. Это снижает прибыль через возвратную логистику и списание части прямых затрат.

5.3. Региональное качество доставки




Рисунок 4. Доля нарушений SLA по регионам

Наибольшая доля нарушений SLA наблюдается в регионе «Новосибирская область» - 51,0%. Это основание для проверки пропускной способности сортировочного узла, маршрутов последней мили и реалистичности обещанного срока.

6. Проверка статистических гипотез

Уровень статистической значимости принят равным 0,05. Для категориальных признаков используется критерий хи-квадрат. Для распределений маржинальности и количества, не предполагающих нормальность, используется критерий Манна-Уитни.

Код	Метод	Статистика	p-value	Результат	Интерпретация
H1	Критерий хи-квадрат	348.20	1.04e-77	Подтверждена	Express: 0.228; Standard: 0.340
H2	Критерий хи-квадрат	515.90	3.29e-114	Подтверждена	Apparel: 0.145; Other: 0.055
H3a	Критерий Манна-Уитни	64108405.00	0.451	Не подтверждена	High discount qty mean: 2.08; Other: 2.10
H3b	Критерий Манна-Уитни	27155140.00	0	Подтверждена	High discount margin: 0.228; Other: 0.357




Рисунок 5. Нарушения SLA по типу доставки

Правильная интерпретация

Статистическая значимость говорит о несовместимости наблюдаемых данных с нулевой гипотезой при выбранной модели теста. Она не доказывает причинность. Экспресс-доставка может отличаться по географии, складам и типам заказов; для причинного вывода нужен контроль смешивающих факторов.

7. ABC-XYZ-анализ товарного портфеля

ABC-класс определяется по накопленной доле выручки: А - первые 80%, В - следующие 15%, С - оставшиеся 5%. XYZ-класс определяется по коэффициенту вариации месячного спроса: X - до 0,50; Y - 0,50-1,00; Z - выше 1,00.




Рисунок 6. Матрица ABC-XYZ

Сегмент	Смысл	Рекомендация
AX	Высокая выручка и стабильный спрос	Высокая доступность, точный safety stock
AZ	Высокая выручка и нестабильный спрос	Планирование по событиям, ручной контроль закупок
CX	Низкий вклад и стабильный спрос	Автоматизированное пополнение небольшими партиями
CZ	Низкий вклад и нестабильный спрос	Сокращение ассортимента или поставка под заказ

8. RFM-анализ клиентской базы

Recency показывает давность последнего заказа, Frequency - число выполненных заказов, Monetary - суммарную признанную выручку клиента. Показатели преобразованы в квинтильные оценки от 1 до 5 и объединены в бизнес-сегменты.




Рисунок 7. RFM-сегменты

Сегмент	Описание	Действие	KPI
Champions	Недавно покупали, часто и много	Ранний доступ, персональные предложения	Retention, выручка на клиента
Loyal	Высокая частота повторных заказов	Программа лояльности и cross-sell	Repeat rate
Potential	Недавние, но пока редкие покупки	Онбординг и второй заказ	Conversion to 2nd order
At Risk	Ранее активные, давно не покупали	Win-back сценарий	Reactivation rate
Hibernating	Редкие и давние покупки	Недорогая реактивация или исключение	Cost per reactivation

9. Аналитическое приложение в Yandex DataLens

В BI загружается единая денормализованная витрина `ecommerce_datamart.csv`. Такой подход уменьшает риск размножения строк и облегчает сверку с Python. Отдельные таблицы RFM и ABC-XYZ могут быть подключены как самостоятельные датасеты или присоединены к основной витрине по `customer_id` и `product_id`.

Макет дашборда DataLens: операционная аналитика e-commerce




Рисунок 8. Макет итогового дашборда DataLens

9.1. Структура дашборда

Вкладка	Объекты	Селекторы	Управленческий вопрос
Управленческий обзор	4 KPI, динамика, категории, карта, региональная таблица	Период, регион, категория, канал	Где формируется результат и где возникает риск?
Сегменты и риски	Возвраты, SLA, отрицательная маржа, RFM, ABC-XYZ	Тип доставки, статус, кампания, высокий дисконт	Какие сегменты требуют действия?
Контроль качества	Пропуски, аномалии, сверка KPI	Период и источник	Совпадают ли расчеты с Python?

9.2. Ключевые вычисляемые поля

Количество заказов = COUNTD([order_id])
Выручка = SUM([recognized_revenue])
Валовая прибыль = SUM([gross_profit])
Маржинальность = SUM([gross_profit]) / SUM([recognized_revenue])
Доля возвратов = SUM([is_returned]) / COUNTD([order_id])
Доля нарушений SLA = SUM([late_flag]) / SUM([sla_eligible])

9.3. QA DataLens

Проверка	Python	DataLens	Ожидаемый статус
Заказы	35915	35915	Совпадает
Клиенты	6143	6143	Совпадает

Проверка	Python	DataLens	Ожидаемый статус
Выручка	328 104 971 руб.	328 104 971 руб.	Совпадает
Маржинальность	26,9%	26,9%	Совпадает
SLA	30,7%	30,7%	Совпадает

10. Рекомендации

Приоритет	Рекомендация	Основание	KPI контроля	Горизонт
Высокий	Пересмотреть SLA и логистические мощности в регионах с высокой просрочкой	Максимум 51,0%	Доля нарушений SLA, средний срок	1-2 месяца
Высокий	Снизить возвраты в одежде через размеры, контент и контроль поставщиков	Возвраты 14,5%	Return rate, валовая прибыль	1 квартал
Средний	Ограничить скидки 20% + товарами с достаточной маржой	Маржа 22,8% против 35,7%	Маржа кампании, объем корзины	4-6 недель
Средний	Настроить адресные сценарии по RFM	Разные профили ценности и давности	Repeat rate, reactivation	1 квартал
Средний	Использовать ABC-XYZ для политики запасов	Различие вклада и стабильности спроса	Out-of-stock, inventory turnover	2-3 месяца
Базовый	Ввести ежемесячную сверку Python и DataLens	Риск расхождения агрегаций	Число несовпадений KPI	Ежемесячно

11. Ограничения исследования

- Данные синтетические и предназначены для учебной демонстрации.
- В наборе нет фактической себестоимости маркетинга, склада и курьерского маршрута.
- Статистические связи не являются причинными эффектами.
- Один заказ соответствует одному товару; реальный заказ может содержать несколько позиций.
- RFM и ABC-XYZ зависят от выбранных порогов и даты среза.
- Дашборд DataLens должен быть проверен в рабочем аккаунте, поскольку доступность функций и расположение элементов могут зависеть от версии и ролей.

12. Заключение

Работа демонстрирует законченный аналитический цикл. Исходные таблицы очищены и объединены в воспроизводимую витрину; выводы подтверждены описательной статистикой и тестами; клиентская база и ассортимент сегментированы; для управленческого использования подготовлена спецификация DataLens и таблица сверки показателей. Основной результат - не набор графиков, а связанная система «бизнес-вопрос -> данные -> метод -> результат -> рекомендация -> KPI контроля».

Приложение А. Контрольные артефакты

- data/processed/ecommerce_datamart.csv - основная витрина DataLens.
- data/processed/rfm_segments.csv - клиентская сегментация.
- data/processed/abc_xyz_products.csv - товарная сегментация.
- notebooks/01_teacher_solution.ipynb - полное воспроизводимое решение.
- datalens/datalens_build_guide.md - подробная спецификация BI.
- materials/consultation_reference.xlsx - критерии, карта дашборда и контрольные значения.

Приложение В. Источники

- **АКИТ. Итоги интернет-торговли за 2025 год:** <https://akit.ru/news/11-5-trln-rublej-akit-podvela-itogi-internet-torgovli-za-2025-god>
- **DataLens. Data model:** <https://datalens.tech/docs/en/dataset/data-model.html>
- **DataLens. Selectors:** <https://datalens.tech/docs/en/dashboard/selector.html>
- **DataLens. Aggregate functions:** <https://datalens.tech/docs/ru/function-ref/aggregation-functions.html>
- **DataLens. Roles:** <https://datalens.tech/docs/ru/security/roles>

Приложение С. Как разбирать отчет на консультации

13. Сначала попросить слушателя назвать бизнес-вопрос и гранулярность данных.
14. Затем проверить ETL по контрольным значениям и логике JOIN.
15. После каждого графика потребовать вывод с конкретным числом.
16. По одной гипотезе пройти H0, H1, метод, p-value, практический смысл и ограничение.
17. В DataLens проверить формулу маржинальности и знаменатель SLA.
18. Завершить тремя рекомендациями с KPI и сроком.